

Département de géomatique appliquée
Faculté des lettres et sciences humaines
Université de Sherbrooke

Modèle de distribution de l'Engoulevent bois-pourri
Preuve de concept d'un SDM Random Forest présence-absence alimenté par les données eBird

Par
Alexandre Chéné

Travail présenté à
Yves Voirin

Dans le cadre du cours
GMQ-580
Géoinformatique II

Sherbrooke
Juillet 2026

Table des matières

Note sur l'utilisation de l'intelligence artificielle (IA)	4
1. Introduction	4
2. Méthodologie	5
3. Algorithme et solution développée	8
3.1. Composite de température de surface par flux STAC	8
3.2. Validation croisée spatiale par blocs.....	9
3.3. Deux modèles complémentaires	9
4. Technologies utilisées	9
4.1. Traitement tabulaire et vectoriel	9
4.2. Traitement raster et acquisition satellitaire	10
4.3. Apprentissage automatique et interprétation	10
4.4. Parallélisation et cartographie	10
5. Résultats	10
6. Conclusion	13
7. Références	15

Liste des figures

Figure 1 : Localisation de la zone d'étude.....	4
Figure 2 : Pipeline de traitement	6
Figure 3 : Entonnoir d'effort d'échantillonnage	7
Figure 4 : Schéma illustrant la composition des modèles Random Forest.	8
Figure 5 : Probabilité de présence prédite à 5 m (modèle combiné, détection standardisée « au crépuscule »).....	12
Figure 6 : Importance par permutation des dix variables du modèle habitat (avec élévation). ...	13

Liste des tableaux

Tableau 1 : Liste des variables d'habitat du modèle.....	7
Tableau 2 : Sources de données, rôle dans le modèle et système de référence (natif puis d'analyse).	10
Tableau 3 : Performance des quatre configurations en validation croisée spatiale (moyenne $\pm$ écart-type sur 5 plis).....	11

Note sur l'utilisation de l'intelligence artificielle (IA)

De grandes portions du code de ce projet ont été générées avec l'aide d'une IA. Ce code a été vérifié et validé par l'étudiant. La logique, l'architecture du pipeline, les choix méthodologiques et l'interprétation des résultats ont toujours été réfléchis et dirigés par l'étudiant.

1. Introduction

L'Engoulevent bois-pourri (*Antrostomus vociferus*) est un insectivore aérien nocturne et crépusculaire, inscrit comme espèce en péril au Canada (ECCC, 2018). Son habitat de reproduction, une mosaïque de forêts semi-ouvertes sur sols secs, demeure mal cartographié, ce qui complique la priorisation des zones de conservation et d'inventaire.

C'est dans ce contexte que ce projet a été développé comme une preuve de concept. L'objectif est d'évaluer la possibilité de bâtir un modèle de distribution d'espèce (SDM) à partir des données de science citoyenne de la plateforme eBird. L'approche retenue repose sur un classificateur par forêt aléatoire (« Random Forest ») en présence-absence, entraîné sur des listes d'observation « zero-remplies », afin de produire une carte de probabilité de présence à 5 m de résolution sur la zone à l'étude (figure 1). Celle-ci s'étend sur un vaste territoire qui englobe notamment les villes de Sherbrooke, Drummondville, Victoriaville et Granby.




Figure 1 : Localisation de la zone d'étude

L'intérêt de ce projet est de déterminer quelles variables environnementales structurent la présence de l'espèce à l'échelle de la zone à l'étude, et où le modèle prédit-il des habitats favorables qui ne sont pas encore documentés par eBird? Quatre hypothèses écologiques guident le choix des variables : l'occurrence augmente avec la densité de lisière forêt-ouvert jusqu'à un optimum intermédiaire (H1) ; les sols bien drainés sont favorisés (H2) ; la densité de routes a un effet non linéaire, positif à faible densité puis négatif au-delà d'un seuil (H3) ; et les peuplements de hauteur et d'âge intermédiaires sont préférés aux peuplements matures fermés (H4).

Ce type de données soulève toutefois plusieurs difficultés qui définissent la problématique du projet. D'abord, le volume et l'hétérogénéité des sources : environ 150 Go de LiDAR brut, des données eBird volumineuses et des couches vectorielles provinciales massives (réseau routier de près de 1,5 million de lignes, milieux humides de près de 2,4 millions de polygones). Ces sources ne tiennent pas en mémoire et diffèrent par leur format, leur résolution et leur système de référence. Ensuite, la rareté de l'espèce : après filtrage, seules 148 présences subsistent sur 17 440 listes complètes, soit un ratio de 0,85 %, ce qui impose une pondération des classes et des métriques robustes au déséquilibre. Enfin, le biais d'effort d'observation : l'engouement n'étant détectable qu'au crépuscule, un modèle naïf apprendrait surtout la détectabilité plutôt que l'habitat. Des variables de détection sont donc introduites, en suivant les bonnes pratiques de Johnston et al. (2021).

2. Méthodologie

Le développement de la solution suit un pipeline séquentiel et reproductible, exécuté script par script et piloté par un fichier de configuration unique. Cette approche rend le pipeline réutilisable d'une analyse à l'autre sans modifier le code : une nouvelle analyse correspond à un nouveau fichier de configuration. Toutes les couches sont harmonisées sur une grille commune à 5 m dans le système de référence EPSG:32198, les sorties raster sont écrites en format COG et le « seed » aléatoire est fixé partout pour garantir la reproductibilité. La démarche se décompose en quatre grandes étapes.

1. Préparation des prédicteurs. Dix variables d'habitat sont produites à 5 m et empilées en un « stack » aligné au pixel près (tableau 1). Une variable thermique, la température de surface estivale, est assemblée à la volée depuis l'archive satellitaire Landsat plutôt que téléchargée en masse.

2. Construction de la table modèle. Les listes complètes eBird sont « zero-remplies » afin de générer des absences confirmées, puis filtrées selon les critères d'effort de Johnston et al. (2021). Les covariables du stack sont extraites dans un rayon de 30 m autour du point d'observation, et quatre variables de détection sont ajoutées pour corriger le biais d'effort.
3. Entraînement et validation. Un modèle Random Forest est optimisé par recherche aléatoire d'hyperparamètres, sous une validation croisée spatiale par blocs qui évite la fuite d'information entre l'entraînement et le test.
4. Prédiction et cartographie. Le modèle est appliqué fenêtré par fenêtré sur l'ensemble du territoire pour produire la carte de probabilité, accompagnée d'une carte d'incertitude, d'une carte des zones d'extrapolation et d'une sélection de secteurs prioritaires d'inventaire.

L'enchaînement de ces étapes, des six sources brutes jusqu'aux cartes finales, est illustré à la figure 2.




Figure 2 : Pipeline de traitement

L'étape de préparation des données eBird mérite une attention particulière, car c'est elle qui conditionne la qualité du jeu d'entraînement. Le passage des 2,9 millions de listes brutes aux 17 440 listes exploitables, dont seulement 148 présences, est présenté sous forme d'entonnoir à la figure 3. Ce fort déséquilibre est au cœur des choix de modélisation décrits à la section suivante.

De 2,9 millions de checklists à la table modèle




Figure 3 : Entonnoir d'effort d'échantillonnage

Tableau 1 : Liste des variables d'habitat du modèle

#	Variable	Source	Échelle
1	Hauteur de canopée (MHC)	LiDAR (MRNF)	5 m + focal
2	Indice topographique d'humidité (TWI)	LiDAR (MNT)	5 m
3	Densité de lisière forêt-ouvert	Écoforestière (MFFP)	focal 1 km
4	Proportion feuillu / mélangé	Écoforestière (MFFP)	focal 500 m
5	Densité de routes	AQréseau+ (Adresses Québec)	focal 1 km
6	Température de surface estivale (LST)	Landsat C2 L2 (STAC)	30 m → 5 m
7	Classe d'âge du peuplement	Écoforestière (MFFP)	5 m
8	Densité du peuplement	Écoforestière (MFFP)	5 m
9	Distance à un milieu humide	Milieux humides potentiels (MELCCFP)	5 m
10	Élévation (MNT)	LiDAR (MRNF)	5 m

À ces dix variables d'habitat s'ajoutent quatre variables de détection, calculées pour chaque liste et destinées uniquement au modèle : les minutes écoulées après le coucher du soleil, la phase lunaire, le logarithme de la durée de la liste et le jour julien. Elles ne sont pas cartographiées mais servent à isoler le signal d'habitat du signal de détectabilité.

3. Algorithme et solution développée

La solution repose sur trois éléments qui la distinguent d'un SDM naïf : un composite thermique assemblé par flux satellitaire, une validation croisée spatiale, et une séparation en deux modèles complémentaires. La figure 4 résume le passage des six sources aux quatorze variables, puis aux deux modèles Random Forest.




Figure 4 : Schéma illustrant la composition des modèles Random Forest.

3.1. Composite de température de surface par flux STAC

La variable thermique est assemblée depuis l'archive Landsat, sans téléchargement en masse. Le catalogue « landsat-c2-l2 » est interrogé par l'entremise de l'interface de programmation STAC du Microsoft Planetary Computer, filtré sur l'emprise de la zone, sur les mois de juin et juillet des années 2013 à 2025, et sur les plateformes Landsat 8 et 9. Les 139 scènes retenues sont chargées en deux bandes : la température de surface brute et le masque de qualité. Chaque scène est nettoyée en masquant les nuages, les ombres de nuages, les nuages dilatés et les cirrus, puis convertie en degrés Celsius. La réduction temporelle est une médiane des scènes claires, robuste aux résidus nuageux, ce qui porte à 42 le nombre médian d'observations claires par pixel. Les quelques trous résiduels sont comblés par interpolation locale, pour un composite final sans valeur manquante, reprojeté et rééchantillonné à 5 m sur la grille commune.

3.2. Validation croisée spatiale par blocs

Les observations d'une espèce sont spatialement autocorrélées et une validation croisée aléatoire laisserait fuiter de l'information de l'entraînement vers le test, ce qui gonflerait artificiellement les métriques. La zone à l'étude est donc découpée en blocs réguliers de 10 km, et des blocs entiers sont assignés à l'entraînement ou au test, jamais scindés. Comme les 148 présences ne tombent que dans 28 blocs, un simple découpage par groupes produirait des plis presque vides de présences. On retient donc une variante stratifiée à cinq plis, qui équilibre au mieux le ratio présence-absence tout en respectant l'intégrité des blocs. C'est sur cette validation qu'est conduite l'optimisation des hyperparamètres. Cette rigueur explique que les scores, quoique élevés, restent honnêtes : ils mesurent la capacité à prédire dans des secteurs non vus pendant l'entraînement.

3.3. Deux modèles complémentaires

L'engouement n'est détecté qu'au crépuscule et les variables de détection dominent la discrimination. Un modèle unique masquerait donc l'écologie derrière la détectabilité. Deux modèles sont par conséquent entraînés. Le premier (combiné), utilise les quatorze variables et produit la carte. Au moment de la prédiction, la détection est fixée à des valeurs standardisées « au crépuscule », suivant l'approche de Johnston et al. (2021). Le second (habitat), n'utilise que les dix variables d'habitat et sert à l'interprétation des hypothèses écologiques. Une procédure séparée a servi à évaluer le rôle de l'élévation, qui ressort comme le prédicteur d'habitat dominant. En comparant les variantes avec et sans élévation, il est démontré qu'elle agit en partie comme un « proxy » spatial de la position géographique, tout en conservant un signal altitudinal propre minoritaire.

4. Technologies utilisées

Le projet est développé en Python et son environnement est géré avec l'outil « uv », dont le fichier de verrouillage est versionné pour assurer la reproductibilité. Les principales bibliothèques sont regroupées ci-dessous selon leur rôle.

4.1. Traitement tabulaire et vectoriel

La bibliothèque « polars » assure la lecture paresseuse des données eBird volumineuses et est déjà multi-threadé. La bibliothèque « geopandas » gère les couches vectorielles (réseau routier,

milieux humides), avec une lecture filtrée sur l'emprise de la zone pour éviter de charger les couches provinciales entières.

4.2. Traitement raster et acquisition satellitaire

Les traitements raster reposent sur « rasterio » et « rioarray » en lecture fenêtrée. Le composite thermique est assemblé au moyen de « pystac-client », « planetary-computer » et « odc-stac », qui interrogent l'archive Landsat par l'interface STAC et chargent les scènes de façon paresseuse. Les statistiques focales séparables sont calculées avec « scipy.ndimage », et l'indice topographique d'humidité est dérivé du modèle numérique de terrain avec « whitebox ».

4.3. Apprentissage automatique et interprétation

Le cœur du modèle est le « RandomForestClassifier » de « scikit-learn », qui prend aussi en charge la validation spatiale, la recherche d'hyperparamètres et l'importance par permutation. L'interprétation des contributions est complétée par « shap », et la position solaire et lunaire nécessaire aux variables de détection est calculée avec « astral ».

4.4. Parallélisation et cartographie

La parallélisation suit une stratégie hybride, en choisissant l'outil selon la charge : « dask » pour les traitements raster massifs et paresseux, le paramètre de multi-cœurs de « scikit-learn » pour l'entraînement, et « polars », déjà multi-threadé, pour le tabulaire. Les cartes finales sont produites avec « matplotlib » et « contextily ». Les sources de données et leurs systèmes de référence sont présentés au tableau 2.

Tableau 2 : Sources de données, rôle dans le modèle et système de référence (natif puis d'analyse).

Source	Rôle	SRC (natif → analyse)
eBird (Cornell Lab)	Observations et listes complètes (zero-fill)	EPSG:4326 → 32198
LiDAR – MHC, MNT (MRNF)	Canopée, élévation, TWI	EPSG:2949 → 32198
Carte écoforestière (MFFP)	Âge, densité, composition du peuplement	EPSG:32198
Landsat C2 L2 (STAC)	Température de surface estivale	UTM → 32198
AQréseau+ (Adresses Québec)	Densité de routes	Lambert MTQ → 32198
Milieux humides potentiels (MELCCFP)	Distance à un milieu humide	EPSG:32198

5. Résultats

Deux métriques complémentaires sont rapportées pour chaque modèle. L'aire sous la courbe ROC (AUC) mesure la qualité du classement des sites, indépendamment d'un seuil et de façon

robuste au déséquilibre. Le TSS (« True Skill Statistic ») est évalué à un seuil de décision et traduit l'utilité opérationnelle une fois la carte convertie en zones favorables ou défavorables. Le tableau 3 compare les quatre configurations en validation croisée spatiale.

Tableau 3 : Performance des quatre configurations en validation croisée spatiale (moyenne $\pm$ écart-type sur 5 plis).

Configuration	AUC-ROC	TSS
Combiné · avec élévation	0,978 $\pm$ 0,009	0,884 $\pm$ 0,056
Combiné · sans élévation	0,965 $\pm$ 0,024	0,880 $\pm$ 0,067
Habitat · avec élévation	0,859 $\pm$ 0,032	0,677 $\pm$ 0,037
Habitat · sans élévation	0,753 $\pm$ 0,085	0,491 $\pm$ 0,132

Le modèle combiné atteint une AUC de 0,978, mais cette quasi-perfection mesure surtout la capacité à distinguer une liste faite au bon moment d'une liste faite trop tôt. La variable « minutes après le coucher du soleil » écrase à elle seule tous les prédicteurs d'habitat. C'est précisément ce qui justifie la production de la carte à détection fixée. La carte de probabilité obtenue est présentée à la figure 5. Elle met en évidence des noyaux d'habitat favorable (hotspots) qui représentent les zones d'intérêt pour la recherche.




Figure 5 : Probabilité de présence prédite à 5 m (modèle combiné, détection standardisée « au crépuscule »).

Une fois le signal de détection fixé, le modèle habitat livre un portrait de l'écologie de l'espèce (figure 6). La hiérarchie des variables non altitudinales place en tête la densité de routes, la proportion de feuillu et mélangé, la température de surface estivale et la densité de lisière. Les profils de dépendance partielle appuient les hypothèses. L'effet non linéaire de la densité de routes (H3) et la préférence pour des structures semi-ouvertes de hauteur et d'âge intermédiaires (H4) sont nettement soutenus, tandis que le drainage (H2) et la densité de lisière (H1) jouent un rôle plus discret. Le fait que le modèle retrouve, à partir de covariables indépendantes, l'écologie décrite dans la littérature constitue une validation qualitative complémentaire aux métriques.




Figure 6 : Importance par permutation des dix variables du modèle habitat (avec élévation).

Enfin, huit secteurs combinant une forte probabilité prédite et un faible effort d'échantillonnage eBird sont proposés comme cibles d'inventaire prioritaires. Ils désignent des habitats favorables mais peu échantillonnés.

6. Conclusion

Cette preuve de concept démontre qu'une chaîne géomatique complète et reproductible peut mener de données brutes hétérogènes jusqu'à une carte de probabilité de présence à 5 m, validée spatialement, pour une espèce en péril. L'objectif initial est donc atteint. Les données de science citoyenne, correctement filtrées et « zero-fillées », permettent bel et bien d'entraîner un SDM Random Forest, potentiellement utile à la conservation.

Plusieurs difficultés ont dû être surmontées en cours de développement. Le volume et l'hétérogénéité des sources de données ont imposé un traitement systématiquement fenêtré et une harmonisation stricte sur une grille unique. Le très faible nombre de présences a exigé une pondération des classes et une validation spatiale adaptée. De plus, ceci augment significativement la variance entre les plis, surtout pour le modèle habitat sans élévation. La nature strictement crépusculaire de l'espèce a obligé la séparation des variables de détection et de l'habitat, sans quoi le modèle aurait surtout appris les conditions d'observation. La forte

structure spatiale de l'élévation a par ailleurs rappelé qu'un prédicteur dominant peut agir comme un simple substitut de la position géographique.

Plusieurs avenues permettraient d'enrichir la solution. Les attributs de type de route et de milieu humide, déjà préservés lors du prétraitement, ouvriraient la porte à des variables stratifiées. L'ajout de prédicteurs Sentinel-2, comme des indices de végétation et d'humidité, et l'extension du pipeline à d'autres territoires constitueraient les prolongements naturels de cette preuve de concept.

7. Références

- Environnement et Changement climatique Canada (2018) Programme de rétablissement de l'Engoulevent bois-pourri (*Antrostomus vociferus*) au Canada. ECCC, Ottawa. [En ligne] <https://www.canada.ca/fr/environnement-changement-climatique/services/registre-public-especes-peril/programmes-retablissement/engoulevent-bois-pourri-2018.html> (Page consultée le 22 juillet 2026)
- Johnston, A., Hochachka, W. M., Strimas-Mackey, M. E. et al. (2021) Analytical guidelines to increase the value of community science data: an example using eBird data to estimate species distributions. *Diversity and Distributions*, vol. 27, no 7, p. 1265-1277. [En ligne] <https://doi.org/10.1111/ddi.13271> (Page consultée le 22 juillet 2026)